


Machine learning for everyone

Dr. sc. nat. Juan Pablo Carbajal

September 7, 2017

Background



1 Introducing myself

2 Intelligence?

- A game!
- Characters and meaning



3 Machine Learning

- The learning problem
- From text to numbers
- Example

4 Closing

Intelligence

A game!



Rule

If a card has a **vowel** on one side, then it must have an **even number** on the other side.

Which cards do you need to check, to know whether the statement is correct?

A game!



Age?



No drink



Under age




Adult

Law

If a person is **drinking alcohol**, then they must be **at least 18**.

Whom do you need to check, to know whether the law is obeyed?

Solution




Rule

If a card has a **vowel** on one side, then it must have an **even number** on the other side.

Which cards do you need to check, to know whether the statement is correct?

Solution



Rule

If a card has a **vowel** on one side, then it must have an **even number** on the other side.

Which cards do you need to check, to know whether the statement is correct?

Solution




Law

If a person is **drinking alcohol**, then they must be **at least 18**.

Whom do you need to check, to know whether the law is obeyed?

Discussion



...if a machine is expected to be *infallible*,
it cannot also be *intelligent*.

– Alan Turing. Talk at the Mathematical Society Feb. 20, 1947

What's the character?

CAT

ABC

What's the character?

TAE

12
13
14

What's the character?

T
C A T
E

12
A 13 C
14

Does it make sense?

Time flies like an arrow.
Fruit flies like an apple.

Scoutmaster: Time flies.
Smart Tenderfoot: You can't. They
go too fast.


Machine learning & Text

The learning problem

to use a set of observations to uncover an underlying process.

For prediction (maybe for understanding).

The learning problem



From text to numbers

Vectorization

Adcirca®

Eli Lilly (Suisse) SA

Zusammensetzung

Wirkstoff: Tadalafil.

Hilfsstoffe: Laktose, Excipients pro compresso obducto.

Galenische Form und Wirkstoffmenge pro Einheit

Filmtabletten zu 20 mg.

Indikationen/Anwendungsmöglichkeiten

Adcirca ist angezeigt zur Behandlung der pulmonalen arteriellen Hypertonie (PAH) der WHO-Funktionsklasse II und III zur Verbesserung der körperlichen Leistungsfähigkeit bei Erwachsenen.

Die Wirksamkeit wurde gezeigt bei idiopathischer PAH (IPAH) und bei PAH aufgrund einer Kollagenose.


Dosierung/Anwendung

Die Behandlung muss von einem Arzt begonnen und überwacht werden, der über ein entsprechendes Fachwissen in der Behandlung der PAH verfügt.

Die empfohlene Dosis beträgt einmal täglich 40 mg (2 Tabletten à 20 mg) und kann zum Essen oder unabhängig von den Mahlzeiten eingenommen werden.

Spezielle Dosierungsanweisungen

vectorization



From text to numbers

Bag of words

- 1 List all words in documents
- 2 For each word: is word in text?

	lorem	ipsum	dolor	sit	amet
	0	1	1	0	0
	1	1	1	0	1
	1	1	0	1	1

TF-IDF

- 1 TF: text frequency
How many times word in text?
- 2 IDF: inverse document frequency
How many texts with that word?

	lorem	ipsum	dolor	sit	amet
	0	0.5	0.3	0	0
	0.25	0.1	0.95	0	0.53
	0.01	0.17	0	0.57	0.03

Adcirca®

Eli Lilly (Suisse) SA

Zusammensetzung

Wirkstoff: Tadalafil.

Hilfsstoffe: Laktose, Excipients pro compresso obducto.

Galenische Form und Wirkstoffmenge pro Einheit

Filmtabletten zu 20 mg.

Indikationen/Anwendungsmöglichkeiten

Adcirca ist angezeigt zur Behandlung der **pulmonalen** arteriellen Hypertonie (PAH) der WHO-Funktionsklasse II und III zur Verbesserung der körperlichen Leistungsfähigkeit bei Erwachsenen.

Die Wirksamkeit wurde gezeigt bei idiopathischer PAH (IPAH) und bei PAH aufgrund einer Kollagenose.

Dosierung/Anwendung

Die Behandlung muss von einem Arzt begonnen und überwacht werden, der über ein entsprechendes Fachwissen in der Behandlung der PAH verfügt.

Adcirca®

Eli Lilly (Suisse) SA

Zusammensetzung

Wirkstoff: Tadalafil.

Hilfsstoffe: Laktose, Excipients pro compresso obducto.

Galenische Form und Wirkstoffmenge pro Einheit

Filmtabletten zu 20 mg.

Indikationen/Anwendungsmöglichkeiten

Adcirca ist angezeigt zur Behandlung der **pulmonalen** arteriellen Hypertonie (PAH) der WHO-Funktionsklasse II und III zur Verbesserung der körperlichen Leistungsfähigkeit bei Erwachsenen.

Die Wirksamkeit wurde gezeigt bei idiopathischer PAH (IPAH) und bei PAH aufgrund einer **Kollagenose**.

Dosierung/Anwendung

Die Behandlung muss von einem Arzt begonnen und überwacht werden, der über ein entsprechendes Fachwissen in der Behandlung der PAH verfügt.

Adcirca®

Eli Lilly (Suisse) SA

Zusammensetzung

Wirkstoff: Tadalafil.

Hilfsstoffe: Laktose, Excipients pro compresso obducto.

Galenische Form und Wirkstoffmenge pro Einheit

Filmtabletten zu 20 mg.


Indikationen/Anwendungsmöglichkeiten

Adcirca ist angezeigt zur Behandlung der **pulmonalen arteriellen** Hypertonie (PAH) der WHO-Funktionsklasse II und III zur Verbesserung der körperlichen Leistungsfähigkeit bei Erwachsenen.

Die Wirksamkeit wurde gezeigt bei **idiopathischer** PAH (IPAH) und bei PAH aufgrund einer **Kollagenose**.

Dosierung/Anwendung

Die Behandlung muss von einem Arzt begonnen und überwacht werden, der über ein



Ben-u-ron	genotox	langfrist	leberschad	hamolyt
Becetamol	genotox	langfrist	leberschad	hamolyt
Vicks MediNait	leberschad	genotox	langfrist	steig
Catapresan	blutdrucksenk	bluthochdruck	langfrist	orthostat
Xylometazolin	systemorganklass	gebrauchsfert	abnehm	bluthochdruck
Rhinatussol	bronchitis	excipi	verhinder	aufzubewahr
Flectoparin	trimenon	richtet	angeseh	excipi
Tamsulosin	orthostat	operativ	resultiert	verbessert
Benidette	venos	hereditar	plotzlich	tagig
Tracleer	pulmonal	funktionell	multipl	angebore
Adcirca	blutdrucksenk	pulmonal	organ	plotzlich
Sildenafil	pulmonal	blutdrucksenk	additiv	moderat
Pramipexol	plotzlich	sedier	patholog	schrittweis
Pirosol	postoperativ	steroidal	manif	eosinophili
Matrifen	ubertrag	trakt	atemdepression	postoperativ
Azelastin	korrigiert	radioaktivitat	langzeit	findet
Scopolamine	kleinkind	reizung	chinidin	hergestellt

- Computers do number crunching, humans provide intelligence.
- Good problem statements → Effective ML.
- Good hypotheses/prior ideas → Effective ML.
- Transforming text to numbers is a delicate step.
- Vocabulary based classification is a way to go for legal-term detection.

Thank you!

Q&A

`ajuanpi@gmail.com`

`juanpablo.carbajal@eawag.ch`